Pix2Pix

최석재 *lingua@naver.com*

Pix2Pix

- Pix2Pix는 입력 이미지의 구조적 특성을 유지하면서 다른 형태로 이미지를 재생성한다
- 입력 이미지와 이에 해당하는 타깃 이미지가 쌍으로 제공되어야 하며,
- 이 타깃 이미지는 입력 이미지의 구조적 특성을 가져야 한다

- 내포하는 U-Net 구조 특성상 이미지의 크기가 줄었들었다가 다시 커지는 인코더 – 디코더의 구조를 가져,
- 크기가 줄어드는 인코더에서 입력 데이터의 특징을 찾아내고,
- 크기가 다시 커지는 디코더에서는 이미지를 생성한다

- 또한 생성자 – 판별자의 구조도 가지고 있어 GAN의 구조도 가지고 있다
- 인코더 – 디코더 구조는 생성자에 해당한다

- 입력 이미지는 정답 이미지의 edge(기본 형상)를 그대로 가지고 있어야 하므로
- 많은 양의 데이터를 확보하기가 어렵다는 점이 단점이다

GAN과의 차이점

- 일반 GAN 알고리즘은 노이즈 벡터를 입력으로 사용하지만
- Pix2Pix는 구조가 있는 이미지를 입력으로 사용한다 (조건부 이미지)
- 그리고 입력 이미지와 정답 이미지와의 관계도 파악한다

- 따라서 일반 GAN은 새로운 이미지를 생성하는 측면이 강하고,
- Pix2Pix는 오토인코더의 경우와 같이 이미지를 변환하는 측면이 강하다

- Pix2Pix는 입력 이미지의 구조와 같은 뚜렷한 특징은 유지하면서
- 텍스처, 색상, 디테일 등 세부적인 특징을 새롭게 생성하는 기법이다

구글 드라이브 연결

- from google.colab import drive
- drive.mount('/content/gdrive')

여기서 사용된 코드는 텐서플로 문서를 참조하였음
https://www.tensorflow.org/tutorials/generative/pix2pix?hl=ko

경로 설정

- import tensorflow as tf
- import os
- import pathlib
- import time
- import datetime

기본 경로

- image_path = '/content/gdrive/MyDrive/pytest_img/'

기본 저장 경로

- save_path = '/content/gdrive/MyDrive/pytest_img/_generated_images/'

저장 경로 생성

기본 저장 경로 밑에 pix2pix 라는 폴더를 만든다

- if not os.path.exists(os.path.join(save_path, "pix2pix/")):
  os.makedirs(os.path.join(os.path.join(save_path, "pix2pix/")))

이미지 확인

- 여기서 사용할 데이터는 건물의 정면(파사드) 이미지를 포함하는 데이터셋이다
- 각 이미지는 256 x 256 이미지 2개가 포함된 형태

tf.io.read_file()은 이미지 파일을 읽어 바이트 타입의 텐서플로 텐서를 반환한다

tf.io.decode_jpeg()은 바이트 데이터를 입력으로 받아 (높이, 너비, 채널)의 3차원 이미지 텐서로 변환한다

- sample_image = tf.io.read_file(image_path+'facades/train/1.jpg')
- sample_image = tf.io.decode_jpeg(sample_image) # RGB 변환
- print(sample_image.shape) # (256, 512, 3)

이미지 확인

- from matplotlib import pyplot as plt
- from IPython import display

- plt.figure()
- plt.imshow(sample_image)

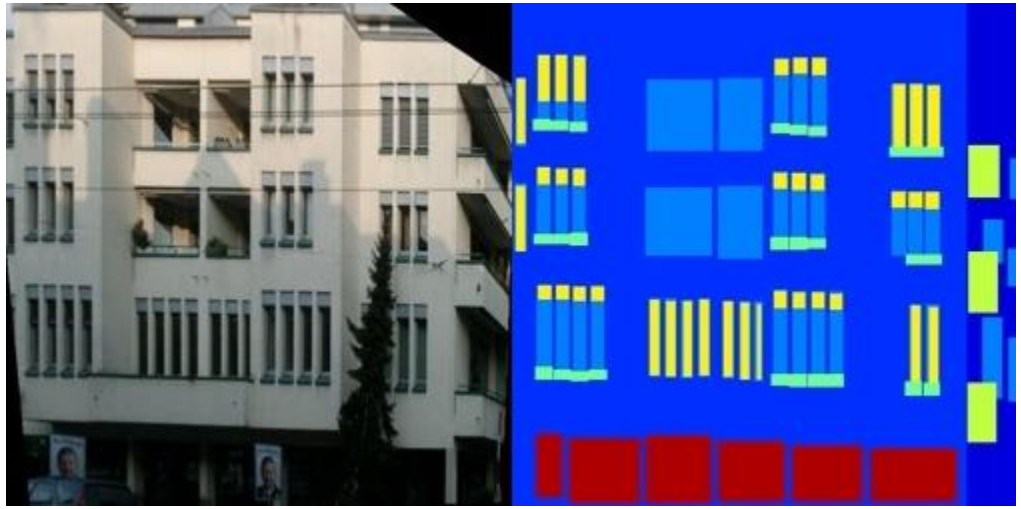

정답 이미지와 입력 이미지가 가로 방향으로 붙어있다

이미지 로딩 함수

- def load(image_file):

```
    image = tf.io.read_file(image_file)                # 이미지를 바이트 타입으로 읽는다
    image = tf.io.decode_jpeg(image)                   # 바이트 타입의 이미지를 JPEG 형식으로 디코딩. 각 픽셀은 0~255의 값

    # 이미지가 가로 방향의 두 부분으로 나뉘어 있다고 가정하고, 중간 지점에서 분할한다
    w = tf.shape(image)[1]                             # (256, 512, 3)의 width에 해당하는 512.
    w = w // 2                                         # 절반값 구함 (256)
    input_image = image[:, w:, :]                      # 입력 이미지. 오른쪽 절반 추출 (건물 아키텍처 레이블 이미지)
    real_image = image[:, :w, :]                       # 정답 이미지. 왼쪽 절반 추출 (실제 건물 파사드 이미지)

    # 두 이미지를 float32 타입으로 변환
    input_image = tf.cast(input_image, tf.float32)
    real_image = tf.cast(real_image, tf.float32)

    return input_image, real_image
```

샘플 이미지 로딩 및 출력

- 한 개 이미지를 로드한 뒤, 입력(input)과 정답(real)으로 분할하고,
- 분할이 잘 되는지를 확인한다

- inp, re = load(image_path+"facades/train/1.jpg")

255로 나누어 정규화한 뒤 시각화 (0.0 ~ 1.0 사이의 값)

- plt.figure()
- plt.imshow(inp / 255.0)
- plt.figure()
- plt.imshow(re / 255.0)

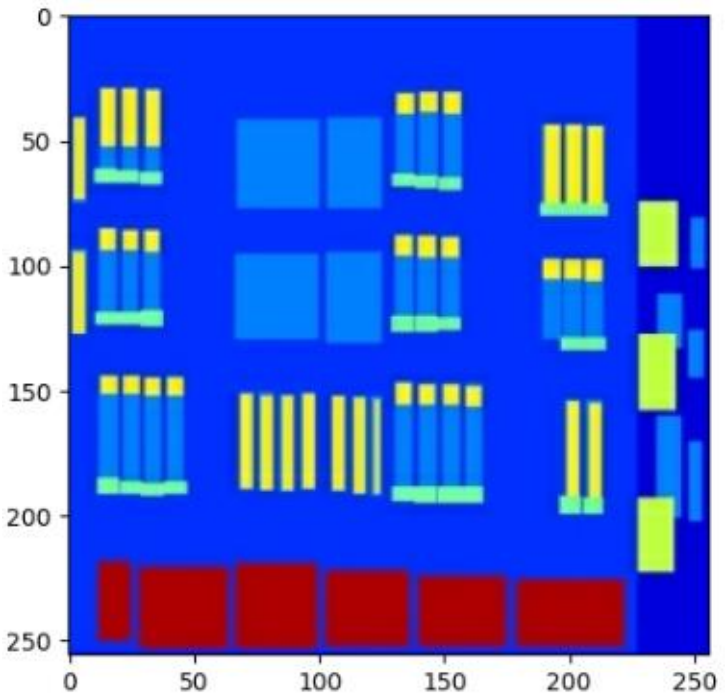

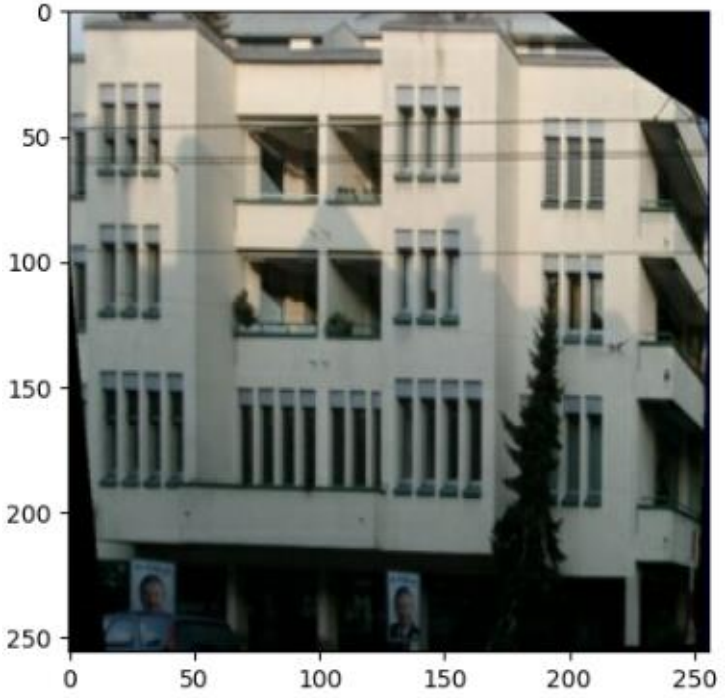

사이즈 조절 함수

- 모든 이미지를 동일한 사이즈로 조절한다

- BUFFER_SIZE = 400 # train 데이터로 사용되는 이미지의 개수
- BATCH_SIZE = 1 # 한 번에 처리되는 이미지의 수. 일반적으로 1을 사용
- IMG_HEIGHT = 256 # 변경되는 이미지의 높이
- IMG_WIDTH = 256 # 변경되는 이미지의 너비

- def resize(input_image, real_image, height, width):

```
input_image = tf.image.resize(input_image, [height, width], method=tf.image.ResizeMethod.NEAREST_NEIGHBOR)
real_image = tf.image.resize(real_image, [height, width], method=tf.image.ResizeMethod.NEAREST_NEIGHBOR)

return input_image, real_image
```

가장 가까운 이웃 픽셀의 값을 복사하여 새로운 픽셀값을 결정하는 방법
edge와 같은 주요 특징을 잘 보존한다

랜덤 CROP 함수

- 입력 이미지와 정답 이미지를 받아서 무작위로 잘라내는 함수
- 다양한 이미지를 생성하여 학습 데이터를 늘리는 데 사용된다 (데이터 증강)

- def random_crop(input_image, real_image):

```
    stacked_image = tf.stack([input_image, real_image], axis=0)  # 두 이미지를 배치 차원을 추가해 결합 (2, 높이, 너비, 채널)
    cropped_image = tf.image.random_crop(                        # 랜덤 위치에서 이미지를 자르는 함수
        stacked_image, size=[2, IMG_HEIGHT, IMG_WIDTH, 3])       # 2개로, 설정된 높이, 설정된 너비, 3 채널로 자름

    return cropped_image[0], cropped_image[1]                    # 잘린 두 개의 이미지를 return
```

두 이미지는 배치 차원에서 결합되므로
이들을 무작위로 잘라낼 때도 배치 차원에서 잘라진다
자르면 동일한 위치에서 잘리므로 서로 동일한 영역이 잘라져 나온다

정규화 함수

- 이미지의 픽셀값을 -1 ~ 1 사이로 정규화한다
- 현재 이미지의 픽셀값은 0~255 사이이므로 127.5로 나누어 0~2 사이로 만든 뒤, 1을 제외한다
- 신경망 데이터의 값을 1이 넘지 않는 값으로 입력하면 네트워크(특히 활성화 함수)가 안정적으로 처리한다

- def normalize(input_image, real_image):

```
    input_image = (input_image / 127.5) - 1
    real_image = (real_image / 127.5) - 1

    return input_image, real_image
```

이미지를 시각화할 때는 0~255 사이의 값으로 만들고,
신경망에 주입할 때는 -1 ~ 1 사이의 값으로 만드는 것이 좋다

이미지 증강

- def random_jitter(input_image, real_image):

```
# 이미지를 자르기 전에 286x286으로 약간 키워 자르기 과정에서 다양한 부분을 포함할 수 있게 한다
input_image, real_image = resize(input_image, real_image, 286, 286)
# 랜덤 crop을 수행한다. 이미지는 다시 256x256이 된다
input_image, real_image = random_crop(input_image, real_image)

if tf.random.uniform(()) > 0.5:                # 50%의 확률로 입력 이미지와 정답 이미지를 좌우 반전한다 (데이터 증강)
  input_image = tf.image.flip_left_right(input_image)
  real_image = tf.image.flip_left_right(real_image)

return input_image, real_image                 # 입력 이미지와 정답 이미지 return
```

증강 결과 출력

- train/1.jpg 샘플 이미지에 대한 데이터 증강이 잘 일어났는지 확인한다

- plt.figure(figsize=(8, 8)) # 이미지의 전체 사이즈 설정
- for i in range(4):
    rj_inp, rj_re = random_jitter(inp, re) # 데이터 증강

    plt.subplot(4, 2, 2*i + 1) # 4x2 서브플롯의 각 행 첫 번째 열에 배치 (홀수)
    plt.imshow(rj_inp / 255.0) # 0~255를 0~1 사이로 줄여 표현
    plt.title("Input")
    plt.axis("off")

    plt.subplot(4, 2, 2*i + 2) # 4x2 서브플롯의 각 행 두 번째 열에 배치 (짝수)
    plt.imshow(rj_re / 255.0)
    plt.title("Real")
    plt.axis("off")

- plt.show()

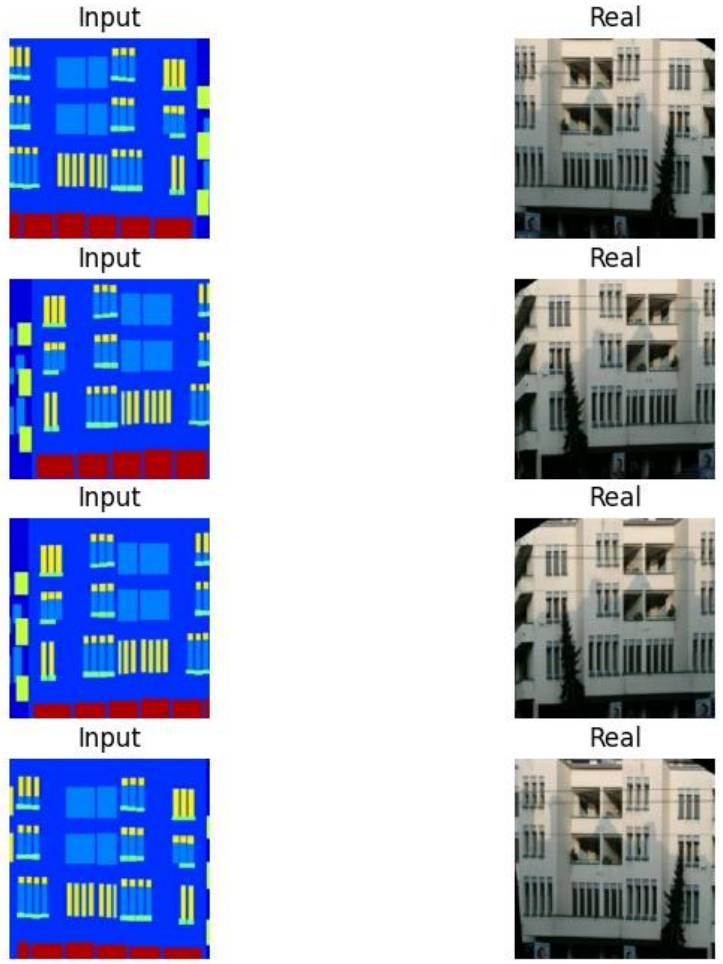

훈련 데이터 준비 함수

- 훈련 데이터 전체에 대하여 로딩, 데이터 증강, 정규화 과정을 수행하는 함수를 정의한다

- def load_image_train(image_file):

  input_image, real_image = load(image_file)

  input_image, real_image = random_jitter(input_image, real_image)

  input_image, real_image = normalize(input_image, real_image)

  return input_image, real_image

테스트 데이터 준비 함수

- 테스트 데이터를 준비하는 함수
- 테스트 데이터는 데이터 증강을 하지 않고, 사이즈 조절만 하는 점이 다르다

- def load_image_test(image_file):

```
input_image, real_image = load(image_file)
input_image, real_image = resize(input_image, real_image, IMG_HEIGHT, IMG_WIDTH)
input_image, real_image = normalize(input_image, real_image)

return input_image, real_image
```

훈련 데이터 전처리 수행

- 대량의 데이터를 처리하는 데 효율적인 tf.data.Dataset을 이용하여 데이터를 전처리한다
- 데이터를 한 번에 메모리에 불러들이지 않고, 배치 단위로 모델에 텐서 형태로 불러들일 수 있다
- tf.data.Dataset.list_files()는 경로상에 * 가 들어가면 지정된 패턴에 맞는 파일을 모두 찾는다
- 또한 다양한 전처리 함수를 제공한다
- https://www.tensorflow.org/api_docs/python/tf/data/Dataset#methods

파일 목록으로부터 파일의 경로를 갖고 있는 Dataset을 만듦

- train_dataset = tf.data.Dataset.list_files(image_path + "facades/train/*.jpg")
- train_dataset = train_dataset.map(load_image_train, num_parallel_calls=tf.data.AUTOTUNE)
- train_dataset = train_dataset.shuffle(BUFFER_SIZE) # 데이터셋을 BUFFER_SIZE 만큼씩 무작위로 섞는다
- train_dataset = train_dataset.batch(BATCH_SIZE) # 데이터셋을 BATCH_SIZE 만큼씩 배치로 분할한다

환경에 맞는 스레드 수로 병렬처리

반복문을 사용하여 각각의 데이터에 접근할 수 있다
텐서 형태의 입력 이미지와 정답 이미지 두 개가 하나의 쌍으로 묶여 있다

```
for i in train_dataset:
  print(i)
```

테스트 데이터 전처리 수행

- 테스트 데이터에 대하여도 셔플만 제외하고 동일한 과정을 수행한다

- test_dataset = tf.data.Dataset.list_files(image_path + "facades/test/*.jpg")
- test_dataset = test_dataset.map(load_image_test)
- test_dataset = test_dataset.batch(BATCH_SIZE)

다운샘플링 모델 생성 함수

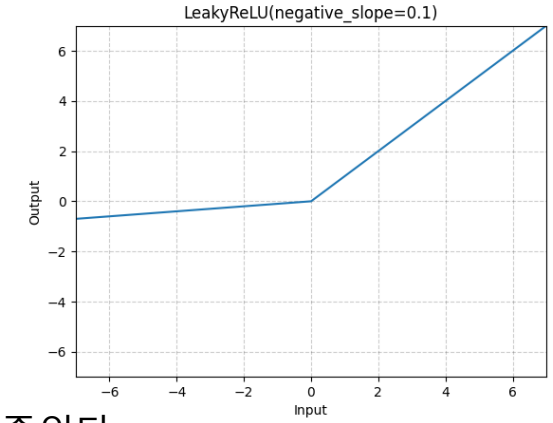

- 인코더에 해당하는 다운샘플링(Downsampling) 모델을 생성하는 함수를 정의한다
- 다운샘플링은 Feature Map의 차원을 줄이는데, 중요한 특징을 학습하면서도 계산 시간과 필요 자원은 줄인다

- def downsample(filters, size, apply_batchnorm=True): # 사용할 필터의 수, 필터의 크기, 배치정규화 여부
  initializer = tf.random_normal_initializer(0., 0.02) # 가중치 초기화. 평균 0, 표준편차 0.02. 안정적 훈련 위해 작은 표준편차 사용

  result = tf.keras.Sequential() # 모델 생성

  배치정규화로 편향 계산은 무효화되므로
  계산의 단순함을 위해 편향은 사용하지 않음

  result.add(tf.keras.layers.Conv2D(filters, size, strides=2, padding='same', kernel_initializer=initializer, use_bias=False))

  모델에 합성곱 층 추가. 입력 데이터에 strides=2와 padding='same'의 2D 합성곱 수행으로 입력 이미지가 절반 크기로 감소됨

  if apply_batchnorm:
    result.add(tf.keras.layers.BatchNormalization()) # 배치정규화 층 추가

  result.add(tf.keras.layers.LeakyReLU()) # 음수에서도 작은 기울기를 허용하는 LeakyReLU 활성화 함수 사용(기본값 0.3)

  특징을 추출하는 과정에서는 양수뿐 아니라, 음수도 받아들여
  다양한 정보를 학습할 수 있게 한다

  return result

다운샘플링 결과 확인

모델을 수행해서 결과를 확인해본다

필터 수 3, 필터 크기 4x4로 합성곱 연산을 수행하는 다운샘플링 모델을 생성한다

- down_model = downsample(3, 4)

먼저 이미지에 배치 차원을 추가한 후,

생성된 모델로 이미지에 다운샘플링을 적용한다

(256, 256, 3) → (1, 128, 128, 3)

- down_result = down_model(tf.expand_dims(inp, 0))
- print (down_result.shape) # (1, 128, 128, 3) 으로 사이즈가 줄어들었다

업샘플링 모델 생성 함수

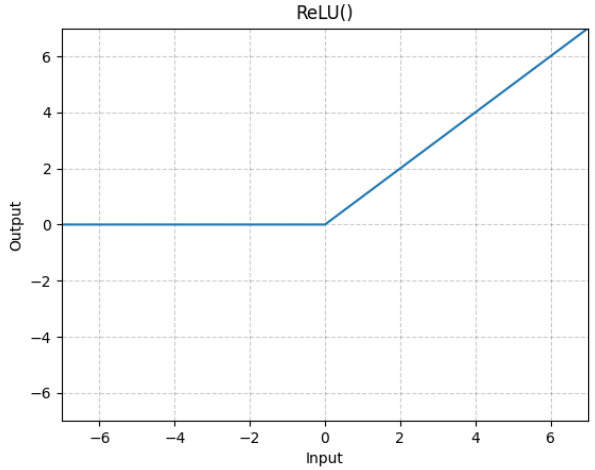

- 디코더에 해당하는 업샘플링(Upsampling) 모델을 생성하는 함수를 정의한다
- 업샘플링은 Feature Map의 차원을 증가시키는 과정으로, 이미지를 복원한다

```
def upsample(filters, size, apply_dropout=False):          # 사용할 필터의 수, 필터의 크기, 드롭아웃 적용 여부
  initializer = tf.random_normal_initializer(0., 0.02)     # 가중치 초기화. 평균 0, 표준편차 0.02

  result = tf.keras.Sequential()                           # 모델 생성
  result.add(tf.keras.layers.Conv2DTranspose(filters, size, strides=2, padding='same', kernel_initializer=initializer, use_bias=False))
        모델에 전치 컨볼루션(역합성곱) 층 추가. 입력 데이터에 0을 넣어 데이터를 키운 뒤 합성곱 연산하는 역합성곱을 통해 이미지의 사이즈를 키운다
  result.add(tf.keras.layers.BatchNormalization())         # 배치정규화 층 추가

  if apply_dropout:
      result.add(tf.keras.layers.Dropout(0.5))             # 드롭아웃 층 층가

  result.add(tf.keras.layers.ReLU())                       # 음수 입력에 0을 출력하는 ReLU 활성화 함수 사용
                                                           양수 범위의 픽셀을 강조해야 자연스러운 이미지가 재구성된다
  return result
```

Conv2DTranspose

- 일반적인 합성곱이 왼쪽과 같이 입력에 대하여 필터를 움직이며 output size를 줄이는데,
- 역합성곱은 오른쪽과 같이 확장된 입력에 대하여 필터를 움직이며 output size를 키운다
- padding='same'을 사용하면 출력 이미지가 입력 이미지 크기의 strides 배수가 되도록 조정한다
- 오른쪽에서 입력 이미지가 2x2, strides=2이므로, 출력 이미지의 크기는 4x4가 되도록 한다

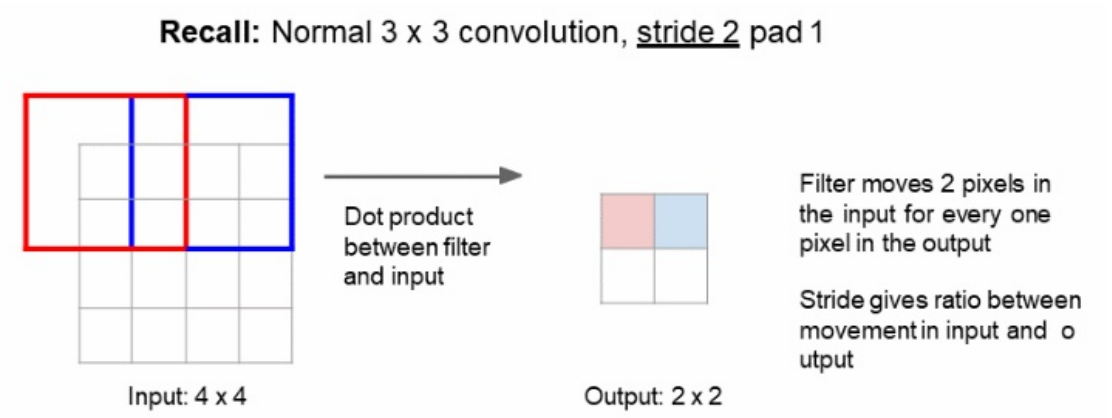

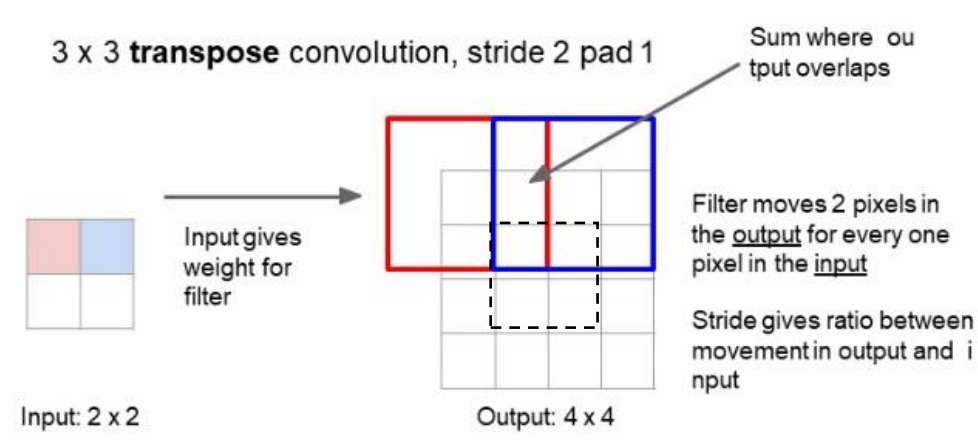

업샘플링 결과 확인

모델을 수행해서 결과를 확인해본다

필터 수 3, 필터 크기 4x4으로 합성곱 연산을 수행하는 업샘플링 모델을 생성한다

- up_model = upsample(3, 4)

앞에서 줄어든 이미지(1, 128, 128, 3)에 업샘플링을 적용한다

- up_result = up_model(down_result)
- print (up_result.shape) # (1, 256, 256, 3). 사이즈가 2배가 되어 본래 크기가 되었다

생성자 함수 (1/4)

- 다운샘플링(인코더)과 업샘플링(디코더)을 연결하여 이미지 생성자를 정의한다

- def Generator():
  inputs = tf.keras.layers.Input(shape=[256, 256, 3]) # 입력층

  down_stack = [# 다운샘플링 스택. 이미지의 차원이 줄어든다
    downsample(64, 4, apply_batchnorm=False), # (batch_size, 128, 128, 64)
    downsample(128, 4), # (batch_size, 64, 64, 128)
    downsample(256, 4), # (batch_size, 32, 32, 256)
    downsample(512, 4), # (batch_size, 16, 16, 512)
    downsample(512, 4), # (batch_size, 8, 8, 512)
    downsample(512, 4), # (batch_size, 4, 4, 512)
    downsample(512, 4), # (batch_size, 2, 2, 512)
    downsample(512, 4), # (batch_size, 1, 1, 512)
  ]

```
def Generator():
  inputs = tf.keras.layers.Input(shape=[256, 256, 3])

  down_stack = [
    downsample(64, 4, apply_batchnorm=False),  # (batch_size, 128, 128, 64)
    downsample(128, 4),  # (batch_size, 64, 64, 128)
    downsample(256, 4),  # (batch_size, 32, 32, 256)
    downsample(512, 4),  # (batch_size, 16, 16, 512)
    downsample(512, 4),  # (batch_size, 8, 8, 512)
    downsample(512, 4),  # (batch_size, 4, 4, 512)
    downsample(512, 4),  # (batch_size, 2, 2, 512)
    downsample(512, 4),  # (batch_size, 1, 1, 512)
  ]

  up_stack = [
    upsample(512, 4, apply_dropout=True),  # (batch_size, 2, 2, 512)
    upsample(512, 4, apply_dropout=True),  # (batch_size, 4, 4, 512)
    upsample(512, 4, apply_dropout=True),  # (batch_size, 8, 8, 512)
    upsample(512, 4),                      # (batch_size, 16, 16, 512)
    upsample(256, 4),                      # (batch_size, 32, 32, 256)
    upsample(128, 4),                      # (batch_size, 64, 64, 128)
    upsample(64, 4),                       # (batch_size, 128, 128, 64)
  ]

  initializer = tf.random_normal_initializer(0., 0.02)
  last = tf.keras.layers.Conv2DTranspose(3, 4,
                                         strides=2,
                                         padding='same',
                                         kernel_initializer=initializer,
                                         activation='tanh')  # (batch_size, 256, 256, 3)

  x = inputs

  skips = []
  for down in down_stack:
    x = down(x)
    skips.append(x)

  skips = reversed(skips[:-1])

  for up, skip in zip(up_stack, skips):
    x = up(x)
    x = tf.keras.layers.Concatenate()([x, skip])

  x = last(x)

  return tf.keras.Model(inputs=inputs, outputs=x)
```

생성자 함수 (2/4)

```
up_stack = [     # 업샘플링 스택. 이미지의 차원이 커진다
  upsample(512, 4, apply_dropout=True),   # (bach_size, 2, 2, 512)
  upsample(512, 4, apply_dropout=True),   # (bach_size, 4, 4, 512)
  upsample(512, 4, apply_dropout=True),   # (bach_size, 8, 8, 512)
  upsample(512, 4),                       # (bach_size, 16, 16, 512)
  upsample(256, 4),                       # (bach_size, 32, 32, 256)
  upsample(128, 4),                       # (bach_size, 64, 64, 128)
  upsample(64, 4),                        # (bach_size, 128, 128, 64)
]
```

```
def Generator():
  inputs = tf.keras.layers.Input(shape=[256, 256, 3])

  down_stack = [
    downsample(64, 4, apply_batchnorm=False),  # (batch_size, 128, 128, 64)
    downsample(128, 4),  # (batch_size, 64, 64, 128)
    downsample(256, 4),  # (batch_size, 32, 32, 256)
    downsample(512, 4),  # (batch_size, 16, 16, 512)
    downsample(512, 4),  # (batch_size, 8, 8, 512)
    downsample(512, 4),  # (batch_size, 4, 4, 512)
    downsample(512, 4),  # (batch_size, 2, 2, 512)
    downsample(512, 4),  # (batch_size, 1, 1, 512)
  ]

  up_stack = [
    upsample(512, 4, apply_dropout=True),  # (batch_size, 2, 2, 512)
    upsample(512, 4, apply_dropout=True),  # (batch_size, 4, 4, 512)
    upsample(512, 4, apply_dropout=True),  # (batch_size, 8, 8, 512)
    upsample(512, 4),                      # (batch_size, 16, 16, 512)
    upsample(256, 4),                      # (batch_size, 32, 32, 256)
    upsample(128, 4),                      # (batch_size, 64, 64, 128)
    upsample(64, 4),                       # (batch_size, 128, 128, 64)
  ]

  initializer = tf.random_normal_initializer(0., 0.02)
  last = tf.keras.layers.Conv2DTranspose(3, 4,
                                         strides=2,
                                         padding='same',
                                         kernel_initializer=initializer,
                                         activation='tanh')  # (batch_size, 256, 256, 3)

  x = inputs

  skips = []
  for down in down_stack:
    x = down(x)
    skips.append(x)

  skips = reversed(skips[:-1])

  for up, skip in zip(up_stack, skips):
    x = up(x)
    x = tf.keras.layers.Concatenate()([x, skip])

  x = last(x)

  return tf.keras.Model(inputs=inputs, outputs=x)
```

생성자 함수 (3/4)

- 최종 이미지 생성

```
initializer = tf.random_normal_initializer(0., 0.02) # 평균 0, 표준편차 0.02
last = tf.keras.layers.Conv2DTranspose(3, 4,
                                       strides=2,
                                       padding='same',
                                       kernel_initializer=initializer,
                                       activation='tanh')  # (batch_size, 256, 256, 3)

x = inputs                             # 모델의 입력을 x에 할당
```

채널 수가 3이 나오도록 filters의 수를 조정

※ initializer는 최초로 사용되는 것으로서 네트워크의 가중치를 초기화하며,
last는 모델의 마지막 출력 레이어로 사용된다

```
def Generator():
  inputs = tf.keras.layers.Input(shape=[256, 256, 3])

  down_stack = [
    downsample(64, 4, apply_batchnorm=False),  # (batch_size, 128, 128, 64)
    downsample(128, 4),  # (batch_size, 64, 64, 128)
    downsample(256, 4),  # (batch_size, 32, 32, 256)
    downsample(512, 4),  # (batch_size, 16, 16, 512)
    downsample(512, 4),  # (batch_size, 8, 8, 512)
    downsample(512, 4),  # (batch_size, 4, 4, 512)
    downsample(512, 4),  # (batch_size, 2, 2, 512)
    downsample(512, 4),  # (batch_size, 1, 1, 512)
  ]

  up_stack = [
    upsample(512, 4, apply_dropout=True),  # (batch_size, 2, 2, 512)
    upsample(512, 4, apply_dropout=True),  # (batch_size, 4, 4, 512)
    upsample(512, 4, apply_dropout=True),  # (batch_size, 8, 8, 512)
    upsample(512, 4),                      # (batch_size, 16, 16, 512)
    upsample(256, 4),                      # (batch_size, 32, 32, 256)
    upsample(128, 4),                      # (batch_size, 64, 64, 128)
    upsample(64, 4),                       # (batch_size, 128, 128, 64)
  ]

  initializer = tf.random_normal_initializer(0., 0.02)
  last = tf.keras.layers.Conv2DTranspose(3, 4,
                                         strides=2,
                                         padding='same',
                                         kernel_initializer=initializer,
                                         activation='tanh')  # (batch_size, 256, 256, 3)
  x = inputs

  skips = []
  for down in down_stack:
    x = down(x)
    skips.append(x)

  skips = reversed(skips[:-1])

  for up, skip in zip(up_stack, skips):
    x = up(x)
    x = tf.keras.layers.Concatenate()([x, skip])

  x = last(x)

  return tf.keras.Model(inputs=inputs, outputs=x)
```

생성자 함수 (4/4)

```
skips = []
for down in down_stack:  # 다운샘플링 스택을 하나씩 실행
  x = down(x)            # 각 다운샘플링 레이어에 입력 x를 전달하여 받음
  skips.append(x)        # 각 다운샘플링 레이어를 통과한 x를 리스트에 추가

skips = reversed(skips[:-1])   # 스킵 리스트의 마지막 직전까지만 슬라이싱한 뒤, 모든 요소를 역순으로 정렬
                               # 마지막 다운샘플링된 요소는 연결되지 않는다

# 각각의 업샘플링 레이어와 스킵 리스트를 하나씩 순회
for up, skip in zip(up_stack, skips):
  x = up(x)                    # 각 업샘플링 레이어에 x를 전달하여 받음
  x = tf.keras.layers.Concatenate()([x, skip])
 # 업샘플링된 이미지 x와 현재 스킵 리스트 요소를 합침
 # 고해상도 정보와 저해상도 정보를 결합하는 것. 기본값 axis=-1로서 채널 차원으로 결합
x = last(x)          # last 레이어를 통과하여 최종 출력을 얻음

return tf.keras.Model(inputs=inputs, outputs=x)
 # 입력과 출력을 지정하여 케라스 모델을 생성하고, return
```

```
def Generator():
  inputs = tf.keras.layers.Input(shape=[256, 256, 3])

  down_stack = [
    downsample(64, 4, apply_batchnorm=False),  # (batch_size, 128, 128, 64)
    downsample(128, 4),  # (batch_size, 64, 64, 128)
    downsample(256, 4),  # (batch_size, 32, 32, 256)
    downsample(512, 4),  # (batch_size, 16, 16, 512)
    downsample(512, 4),  # (batch_size, 8, 8, 512)
    downsample(512, 4),  # (batch_size, 4, 4, 512)
    downsample(512, 4),  # (batch_size, 2, 2, 512)
    downsample(512, 4),  # (batch_size, 1, 1, 512)
  ]

  up_stack = [
    upsample(512, 4, apply_dropout=True),  # (batch_size, 2, 2, 512)
    upsample(512, 4, apply_dropout=True),  # (batch_size, 4, 4, 512)
    upsample(512, 4, apply_dropout=True),  # (batch_size, 8, 8, 512)
    upsample(512, 4),                      # (batch_size, 16, 16, 512)
    upsample(256, 4),                      # (batch_size, 32, 32, 256)
    upsample(128, 4),                      # (batch_size, 64, 64, 128)
    upsample(64, 4),                       # (batch_size, 128, 128, 64)
  ]

  initializer = tf.random_normal_initializer(0., 0.02)
  last = tf.keras.layers.Conv2DTranspose(3, 4,
                                         strides=2,
                                         padding='same',
                                         kernel_initializer=initializer,
                                         activation='tanh')  # (batch_size, 256, 256, 3)

  x = inputs

  skips = []
  for down in down_stack:
    x = down(x)
    skips.append(x)

  skips = reversed(skips[:-1])

  for up, skip in zip(up_stack, skips):
    x = up(x)
    x = tf.keras.layers.Concatenate()([x, skip])

  x = last(x)

  return tf.keras.Model(inputs=inputs, outputs=x)
```

생성자 아키텍처 시각화

- 입력된 텐서는 다운샘플링을 거쳐 (1, 1)의 사이즈로까지 줄어들었다가,
- 업샘플링의 과정을 거쳐 원본 사이즈 (256, 256)으로 커진다
- 그리고 업샘플링하는 사이사이에 Concatenate 과정이 끼어들게 된다

- 다운샘플링 과정에서 이미지의 질감(texture)과 같은 기본적인 저수준의 다양한 특징이 추출되고
- 이를 다시 업샘플링하면서 저수준 특징을 구조와 같은 고수준 특징으로 변환할 수 있게 된다

생성자 모델 반환. 반환된 생성자 모델은 Functional API 모델

- generator = Generator()
- tf.keras.utils.plot_model(generator, show_shapes=True, dpi=64)

※ 인코더 한 레이어에서 디코더의 레이어로 건너뛰어 연결되는 것을 스킵 연결(Skip Connections)이라고 한다
※ 인코더에서는 이미지를 점차 축소하고, 디코더에서는 복원하여 스킵 연결하는 이러한 구조를 U-Net이라고 한다

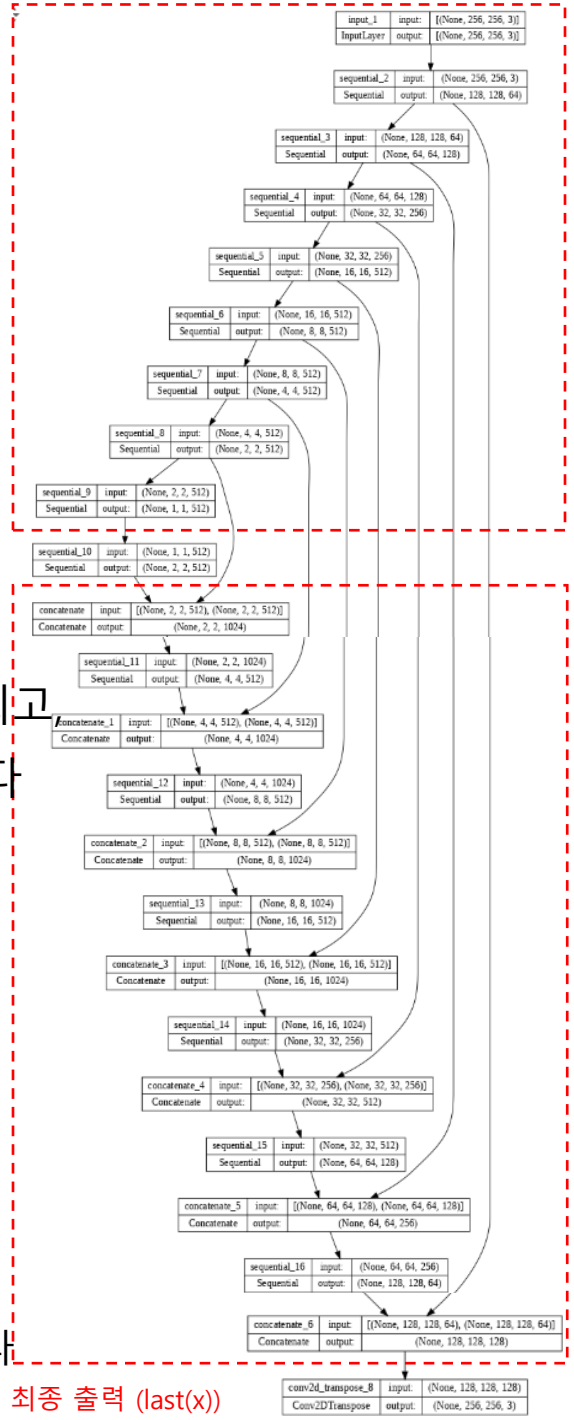

생성자 테스트

- 생성자를 이용하여 이미지가 잘 생성되었는지 확인한다

입력 이미지에 배치 차원을 추가한 뒤, Functional API 모델인 generator에 넣어 이미지를 생성한다
outputs는 Generator의 return에 지정된 대로 기본값인 Generator 과정의 최종 출력 텐서 x가 들어간다
training=False를 수행하면 케라스가 BatchNormalization과 Dropout은 수행하지 않는다

- gen_output = generator(inputs=inp[tf.newaxis, ...], training=False)

배치 차원을 제외한 (H, W, C) 형태로 이미지를 출력한다

- plt.imshow(gen_output[0, ...])

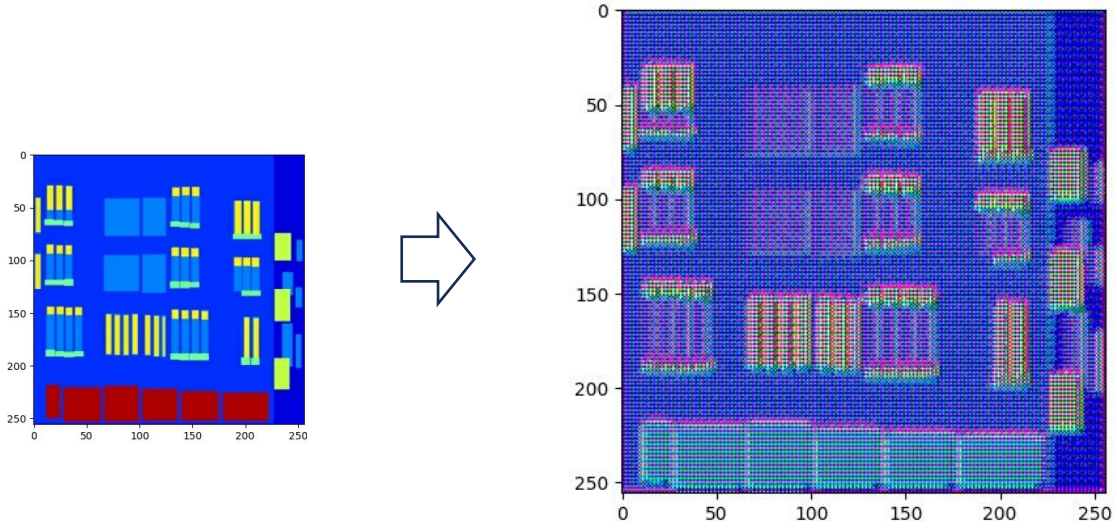

손실함수 객체 생성

- 생성자와 판별자에서 사용할 손실함수 객체를 생성한다

- LAMBDA = 100 # 손실함수 가중치

from_logits=True: 손실함수로 들어오는 입력값이 Sigmoid 함수를 거친 0~1이 아니므로, 내부에서 Sigmoid 변환을 수행하게 한다

- loss_object = tf.keras.losses.BinaryCrossentropy(from_logits=True)

생성자 손실함수 정의

파라미터: 판별자가 생성자의 이미지에 대해 진짜 이미지로 분류할 확률, 생성자의 이미지, 정답 이미지

- def generator_loss(disc_generated_output, gen_output, target):

  # 판별자를 얼마나 잘 속이는지를 측정. 생성된 이미지가 목푯값 1에 얼마나 가까운지(GAN 손실)를 계산 (낮을수록 가까움)

  gan_loss = loss_object(tf.ones_like(disc_generated_output), disc_generated_output)

  1. disc_generated_output과 같은 형상에 목푯값 1을 갖는 배열 생성
  2. 생성된 이미지인 disc_generated_output의 각 셀의 값이 1에 이를 때 가장 작은 값을 갖게 됨

  # 생성된 이미지가 실제 이미지와 얼마나 가까운지를 측정. 정답 이미지와 생성자 이미지 차이의 절대값(L1 손실)의 평균 (낮을수록 좋음)

  l1_loss = tf.reduce_mean(tf.abs(target - gen_output))

  # gan_loss + L1 손실 즉, 가짜를 얼마나 진짜 같이 보였는지로 전체 손실값 계산

  total_gen_loss = gan_loss + (LAMBDA * l1_loss) # 가중치 상수 LAMBDA로 L1 손실의 영향을 조절

  return total_gen_loss, gan_loss, l1_loss # 전체 생성자 손실, GAN 손실, L1 손실을 return

판별자 함수 (1/2)

- 두 개의 이미지를 받아 진짜와 가짜를 구분하는 이미지 판별자를 정의한다

- def Discriminator():

```
initializer = tf.random_normal_initializer(0., 0.02)          # 평균 0, 표준편차 0.02로 가중치 초기화

inp = tf.keras.layers.Input(shape=[256, 256, 3], name='input_image')          # 원본 입력 이미지
tar = tf.keras.layers.Input(shape=[256, 256, 3], name='target_image')         # 진짜 또는 생성된 이미지

# inp와 tar 이미지를 마지막 차원인 채널 기준으로 병합
x = tf.keras.layers.concatenate([inp, tar], axis=-1) # (batch_size, 256, 256, channels*2==6)
# 다운샘플링
down1 = downsample(64, 4, False)(x)                            # (batch_size, 128, 128, 64)
down2 = downsample(128, 4)(down1)                              # (batch_size, 64, 64, 128)
down3 = downsample(256, 4)(down2)                              # (batch_size, 32, 32, 256)
```

진짜 이미지 쌍이 들어올 때는 tar이 진짜 이미지이고, → 진짜로 분류하도록 학습
가짜 이미지 쌍이 들어올 때는 tar이 생성된 이미지이다 → 가짜로 분류하도록 학습

판별자 함수 (2/2)

```
zero_pad1 = tf.keras.layers.ZeroPadding2D()(down3)                    # 제로 패딩 추가. (batch_size, 34, 34, 256)
conv = tf.keras.layers.Conv2D(512, 4, strides=1, kernel_initializer=initializer, use_bias=False)(zero_pad1)
                                                                      # 합성곱 연산. (batch_size, 31, 31, 512)
batchnorm1 = tf.keras.layers.BatchNormalization()(conv)               # 배치 정규화
leaky_relu = tf.keras.layers.LeakyReLU()(batchnorm1)                  # LeakyReLU 활성화 함수 적용

zero_pad2 = tf.keras.layers.ZeroPadding2D()(leaky_relu)               # 제로 패딩 추가. (batch_size, 33, 33, 512)
last = tf.keras.layers.Conv2D(1, 4, strides=1, kernel_initializer=initializer)(zero_pad2)  # (batch_size, 30, 30, 1)

return tf.keras.Model(inputs=[inp, tar], outputs=last)
    # 입력(inp, tar)과 출력(last)을 지정하여 케라스 모델을 생성하고, return
```

단채널이며, 30x30의 각 영역에서의 값이
진짜(1), 가짜(0)이 되도록 훈련된다

판별자 함수 전체 코드

```
def Discriminator():
  initializer = tf.random_normal_initializer(0., 0.02)

  inp = tf.keras.layers.Input(shape=[256, 256, 3], name='input_image')
  tar = tf.keras.layers.Input(shape=[256, 256, 3], name='target_image')

  x = tf.keras.layers.concatenate([inp, tar], axis=-1)  # (batch_size, 256, 256, channels*2)

  down1 = downsample(64, 4, False)(x)  # (batch_size, 128, 128, 64)
  down2 = downsample(128, 4)(down1)  # (batch_size, 64, 64, 128)
  down3 = downsample(256, 4)(down2)  # (batch_size, 32, 32, 256)
```

```
  zero_pad1 = tf.keras.layers.ZeroPadding2D()(down3)  # (batch_size, 34, 34, 256)
  conv = tf.keras.layers.Conv2D(512, 4, strides=1,
                                kernel_initializer=initializer,
                                use_bias=False)(zero_pad1)  # (batch_size, 31, 31, 512)

  batchnorm1 = tf.keras.layers.BatchNormalization()(conv)

  leaky_relu = tf.keras.layers.LeakyReLU()(batchnorm1)

  zero_pad2 = tf.keras.layers.ZeroPadding2D()(leaky_relu)  # (batch_size, 33, 33, 512)

  last = tf.keras.layers.Conv2D(1, 4, strides=1,
                                kernel_initializer=initializer)(zero_pad2)  # (batch_size, 30, 30, 1)

  return tf.keras.Model(inputs=[inp, tar], outputs=last)
```

판별자 아키텍처 시각화

판별자 모델 반환. 반환된 판별자 모델은 Functional API 모델

- discriminator = Discriminator()
- tf.keras.utils.plot_model(discriminator, show_shapes=True, dpi=64)

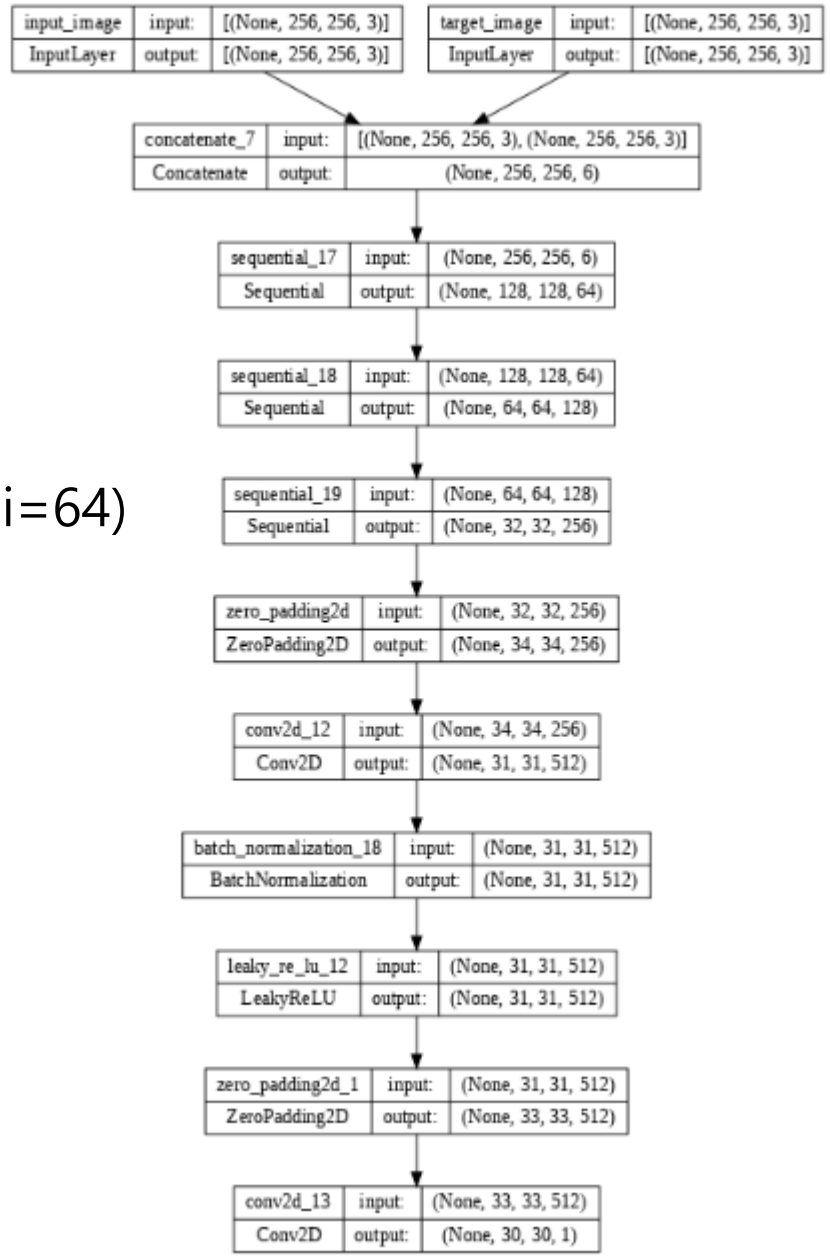

※ 30x30의 작은 이미지로 만들어 시간과 자원 소모를 줄이고,
이미지의 주요 특징을 파악한다
여러 층의 합성곱층을 거친 작은 이미지는 주요 특징을 잘 요약한다

판별자 테스트

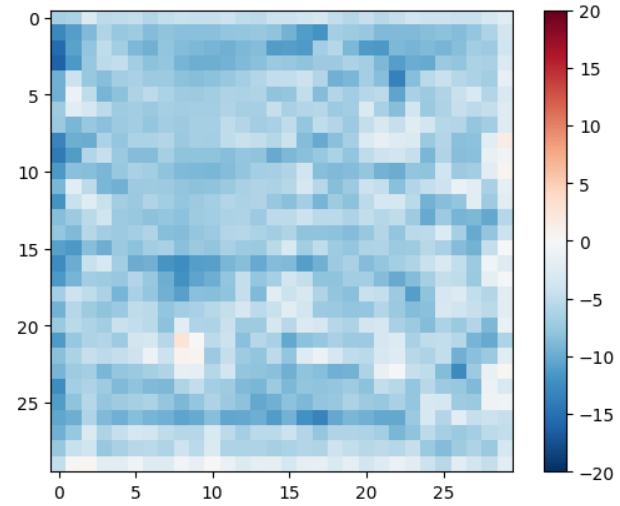

출력 결과가 음수(파란색)이 많다
모델이 이 이미지를 가짜 이미지로 볼 확률이 높음을 의미한다

- 판별자에 입력 이미지와 생성된 이미지를 넣고, 판별자의 출력을 시각화해본다

입력 이미지에 배치 차원을 추가하여 (1, 256, 256, 3) 형태로 만들어 넣는다
생성자 테스트 때 만들어진 생성된 이미지를 넣는다
training=False 하여 배치정규화와 드롭아웃은 수행하지 않는다

- disc_out = discriminator([inp[tf.newaxis, ...], gen_output], training=False)

배치 차원을 제거한 (H, W, C) 형태로 이미지를 출력한다
출력 범위를 -20 ~ 20 사이로 나오게 한다. RdBu_r은 양수는 빨간색으로, 음수는 파란색으로 나오게 하는 컬러맵

- plt.imshow(disc_out[0, ...], vmin=-20, vmax=20, cmap='RdBu_r')
- plt.colorbar()

현재 단계에서는 아직 훈련이 되지 않은 상태이므로 샘플 이미지의 성격만 갖는다

판별자 손실함수 정의

판별자가 정답 이미지를 받아 출력한 결과와 판별자가 생성된 가짜 이미지를 받아 출력한 결과 두 개를 받아
진짜 이미지가 1에 가까운 정도와 가짜 이미지가 0에 가까운 정도를 각각 구한 뒤, 이를 합쳐 전체 손실값으로 받아들인다

- def discriminator_loss(disc_real_output, disc_generated_output):

  # 판별자가 정답 이미지를 진짜로 분류했는지에 대한 손실을 계산 (낮을수록 가까움)

  real_loss = loss_object(tf.ones_like(disc_real_output), disc_real_output)

  1. disc_real_output과 같은 형상에 목푯값 1을 갖는 배열 생성
  2. 정답 이미지인 disc_real_output의 각 셀의 값이 1에 이를 때 가장 작은 값을 갖게 됨

  # 판별자가 가짜 이미지를 가짜로 분류했는지에 대한 손실을 계산 (낮을수록 좋음)

  generated_loss = loss_object(tf.zeros_like(disc_generated_output), disc_generated_output)

  1. disc_generated_output과 같은 형상에 목푯값 0을 갖는 배열 생성
  2. 가짜 이미지인 disc_generated_output의 각 셀의 값이 0에 이를 때 가장 작은 값을 갖게 됨

  # real_loss + generated_loss 즉, 진짜를 진짜로, 가짜를 가짜로 얼마나 잘 분류했는지로 전체 판별자 손실을 계산

  total_disc_loss = real_loss + generated_loss

  return total_disc_loss # 전체 판별자 손실을 return

훈련과정 도식화

- 입력 이미지는 생성자로 들어가서 목푯값 1의
- 손실함수를 거쳐 진짜 같은 가짜 이미지를 만든 뒤
- 판별자로 들어가서 목푯값 0의 손실함수를 거쳐
- 판별자가 가짜 이미지를 잘 판별하도록 하고

- 정답 이미지는 바로 판별자로 들어가 목푯값 1의
- 손실함수를 거쳐 판별자가 진짜 이미지를 잘 판별하도록 한다

- 판별자에서는 이 두 가지를 한 번에 확인하므로
- 진짜와 가짜를 점점 더 잘 구분할 수 있도록 업데이트 되고,
- 생성자는 점점 더 진짜 같은 가짜 이미지를 만들게 된다

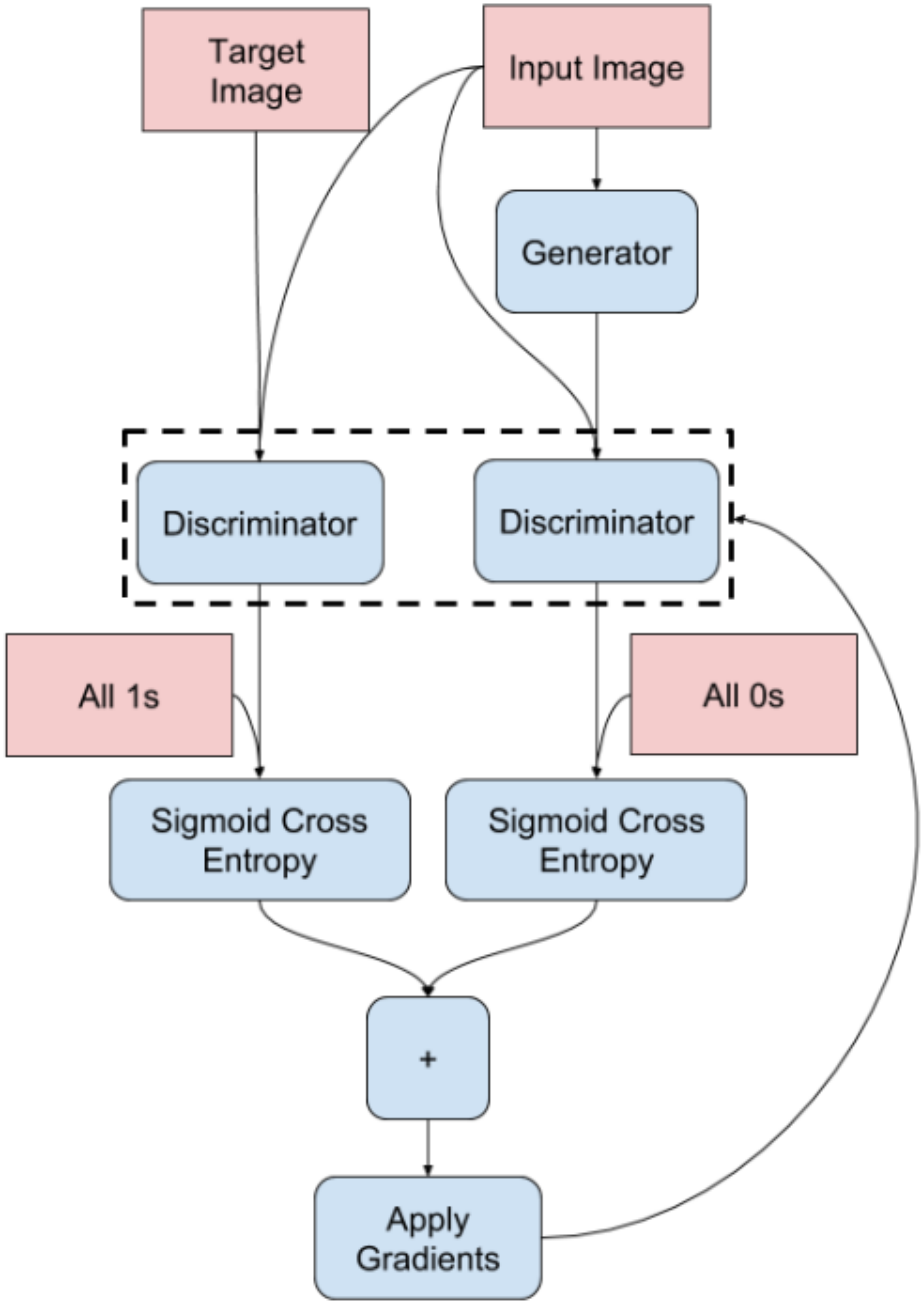

옵티마이저 정의

- 학습률 0.0002, 이전 그라디어트 기여도 0.5로 Adam 옵티마이저를 설정한다

- generator_optimizer = tf.keras.optimizers.Adam(2e-4, beta_1=0.5)
- discriminator_optimizer = tf.keras.optimizers.Adam(2e-4, beta_1=0.5)

체크포인트 생성

- 모델의 중간 학습 상태를 저장해둘 수 있는 체크포인트를 생성한다

- checkpoint_dir = save_path+'pix2pix/training_checkpoints'
- checkpoint_prefix = os.path.join(checkpoint_dir, "ckpt")

체크포인트 경로 생성
- if not os.path.exists(checkpoint_prefix):
  os.makedirs(checkpoint_prefix)

체크포인트 객체 생성. 생성자의 옵티마이저, 판별자의 옵티마이저, 생성자 모델의 가중치, 판별자 모델의 가중치를 저장
- checkpoint = tf.train.Checkpoint(generator_optimizer=generator_optimizer,
  discriminator_optimizer=discriminator_optimizer,
  generator=generator,
  discriminator=discriminator)

이미지 생성 함수

- 모델을 사용하여 입력 이미지, 정답 이미지, 생성된 이미지를 시각화하는 함수

- def generate_images(model, test_input, tar): # 모델, 테스트 입력 이미지, 정답 이미지
  prediction = model(test_input, training=True) # 모델로 입력 이미지를 넣어 이미지를 생성. 학습 모드.
  plt.figure(figsize=(15, 15))

  display_list = [test_input[0], tar[0], prediction[0]] # 첫번째 배치의 입력 이미지, 정답 이미지, 생성 이미지 선택
  title = ['Input Image', 'Ground Truth', 'Predicted Image'] # 각 이미지를 설명하는 제목

  for i in range(3):
    plt.subplot(1, 3, i+1) # 1행 3열의 서브플롯의 i+1번째 위치에 이미지 배치
    plt.title(title[i])
    plt.imshow(display_list[i] * 0.5 + 0.5) # 픽셀값이 -1~1 사이에 있을 수 있으므로 0~1 사이로 오도록 조정
    plt.axis('off')

  plt.show()

함수 테스트

- for example_input, example_target in test_dataset.take(1): # 하나의 배치를 가져온다
  generate_images(generator, example_input, example_target)

아직 학습이 이루어지지 않았기 때문에 생성된 이미지는 품질이 좋지 않다

스텝별 훈련 함수 (1/2)

- 각 훈련 단계에서 생성자와 판별자의 손실을 계산하고, 이를 기반으로 모델 가중치를 업데이트한다

- def train_step(input_image, target, step):

```
  with tf.GradientTape() as gen_tape, tf.GradientTape() as disc_tape:        # 생성자와 판별자의 그래디언트 추적
      gen_output = generator(input_image, training=True)                     # 생성자로 입력 이미지로부터 이미지 생성

      disc_real_output = discriminator([input_image, target], training=True)  # 입력 이미지와 정답 이미지의 판별자 출력 결과
      disc_generated_output = discriminator([input_image, gen_output], training=True) # 입력과 생성 이미지의 판별자 결과

      # 생성자의 전체 손실, GAN 손실, L1 손실 반환
      gen_total_loss, gen_gan_loss, gen_l1_loss = generator_loss(disc_generated_output, gen_output, target)

      # 판별자의 전체 손실
      disc_loss = discriminator_loss(disc_real_output, disc_generated_output)
```

스텝별 훈련 함수 (2/2)

```
# 생성자와 판별자에 대한 그래디언트를 각각 계산
generator_gradients = gen_tape.gradient(gen_total_loss, generator.trainable_variables)
discriminator_gradients = disc_tape.gradient(disc_loss, discriminator.trainable_variables)

# 그래디언트를 이용하여 생성자와 판별자의 가중치 업데이트
generator_optimizer.apply_gradients(zip(generator_gradients, generator.trainable_variables))
discriminator_optimizer.apply_gradients(zip(discriminator_gradients, discriminator.trainable_variables))
```

훈련 함수 (1/2)

```
def fit(train_ds, test_ds, steps, save_path):                # 훈련 데이터셋, 테스트 데이터셋, 훈련 스텝 수
  example_input, example_target = next(iter(test_ds.take(1)))  # 테스트 셋에서 하나의 배치를 가져와 첫 번째 요소를 가져온다
  start = time.time()                                        # 경과 시간 측정용

                                                             # 훈련 스텝 수만큼 훈련 데이터셋을 반복. 반복 횟수(step)와 데이터를 반환
  for step, (input_image, target) in train_ds.repeat().take(steps).enumerate():
    if (step) % 1000 == 0:                                   # 1000 스텝마다 수행
      display.clear_output(wait=True)                        # 기존 출력 화면 지우기

      if step != 0:
        print(f'Time taken for 1000 steps: {time.time()-start:.2f} sec₩n')

      start = time.time()
```

훈련 함수 (2/2)

# 처음에 가져온 이미지가 모델의 훈련이 반복되며 어떻게 달라지는지 확인한다
generate_images(generator, example_input, example_target)
print(f"Step: {step//1000}k")

train_step(input_image, target, step) # 한 스텝의 훈련 수행

# 훈련 과정 표시
if (step+1) % 10 == 0: # 10 스텝마다 점을 표시
  print('.', end='', flush=True) # flush=True로 즉시 출력

# 5000 step마다 모델의 현재 상태를 체크포인트로 저장
if (step + 1) % 5000 == 0:
  checkpoint.save(file_prefix=checkpoint_prefix)

```
def fit(train_ds, test_ds, steps, save_path):
  example_input, example_target = next(iter(test_ds.take(1)))
  start = time.time()

  for step, (input_image, target) in train_ds.repeat().take(steps).enumerate():
    if (step) % 1000 == 0:
      display.clear_output(wait=True)

      if step != 0:
        print(f'Time taken for 1000 steps: {time.time()-start:.2f} sec\n')

      start = time.time()

      generate_images(generator, example_input, example_target)
      print(f"Step: {step//1000}k")

    train_step(input_image, target, step)

    # 훈련 과정 표시
    if (step+1) % 10 == 0:
      print('.', end='', flush=True)

    # 5000 step마다 모델의 현재 상태를 체크포인트로 저장
    if (step + 1) % 5000 == 0:
      checkpoint.save(file_prefix=checkpoint_prefix)
```

훈련 수행

- fit(train_dataset, test_dataset, steps=40000, save_path=save_path)

step 0(첫번째)

step 1000

step 2000

step 3000

step 4000

Step: 4k

step 5000

Step: 5k

step 6000

Step: 6k

step 7000

Step: 7k

step 8000

Step: 8k

step 9000

Step: 9k

step 10000

step 20000

step 30000

step 39000

테스트 데이터 사용

- 훈련이 끝난 모델로 Test Dataset을 사용하여 이미지를 생성해본다

- for inp, tar in test_dataset.take(5): # 5개 배치를 가져온다
  generate_images(generator, inp, tar)

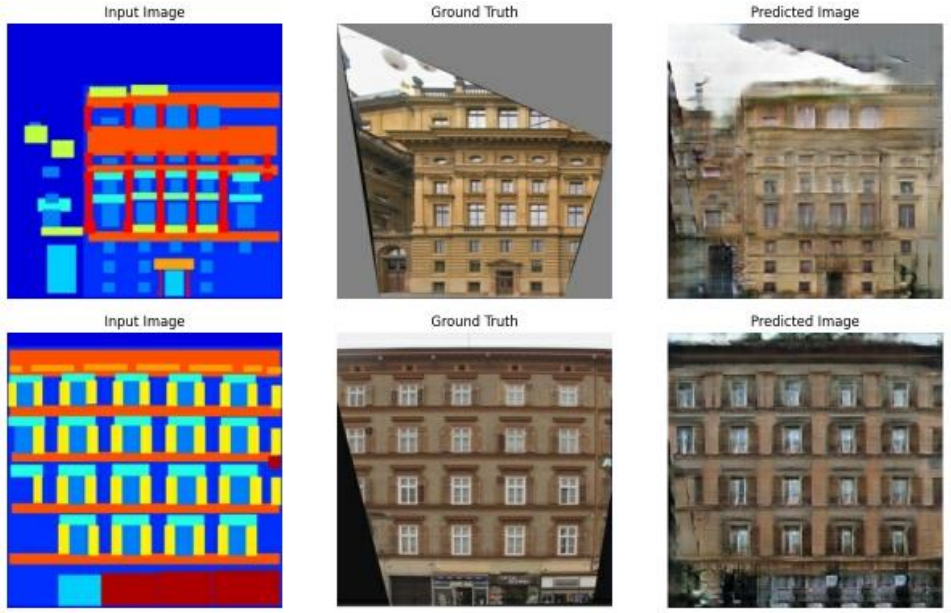

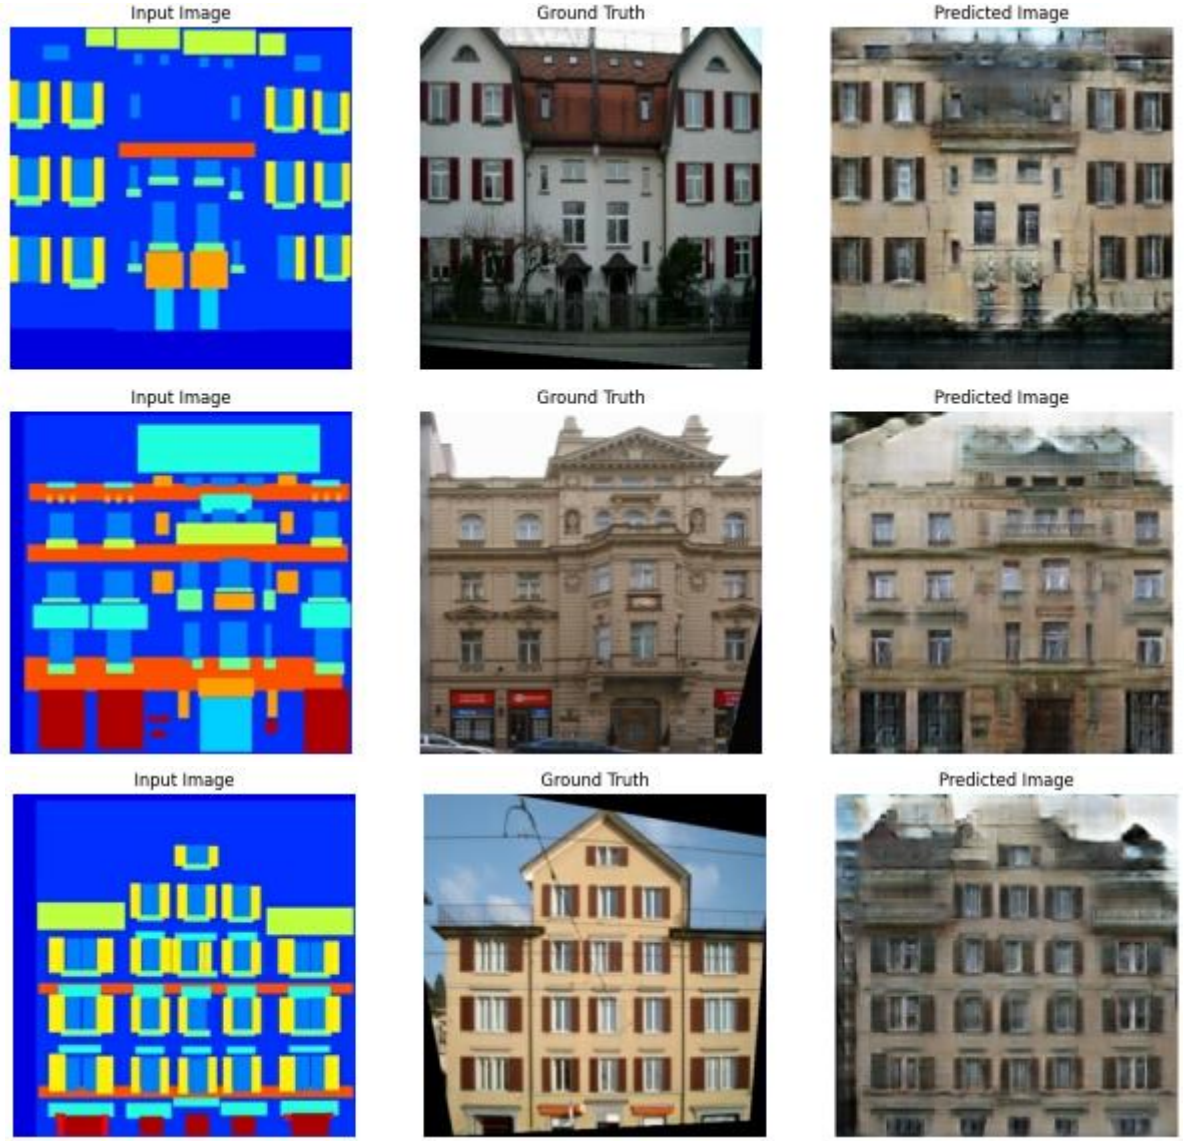

약간 부족한 부분이 있지만 매우 사실적인 이미지이면서도, 원본과는 다른 특성을 갖게 되었다